

Machine Learning  $\rightarrow H(Y) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91$

$x_1: \begin{array}{c|c|c|c} 1 & 0 & 1 & 1 \end{array}$

$\begin{array}{c} \textcircled{1} \quad \textcircled{0} \quad \textcircled{1} \end{array}$  : possible splits

$$\begin{cases} H(Y|\textcircled{1}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91 \\ H(Y|\textcircled{0}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91 \checkmark \\ H(Y|\textcircled{1}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91 \end{cases}$$

$x_2: H(Y|x_2) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91$

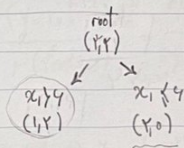
$x_3: \begin{array}{c|c|c} 0 & 1 & 0 \end{array}$

$\begin{array}{c} \textcircled{0} \quad \textcircled{1} \end{array}$  : possible splits

$$\begin{cases} H(Y|\textcircled{0}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91 \\ H(Y|\textcircled{1}) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91 \end{cases}$$

$\rightarrow$  pick min of  $H(Y|?)$  : split on  $x_1 > 0$

$\checkmark$  continue on  $x_1 > 0$

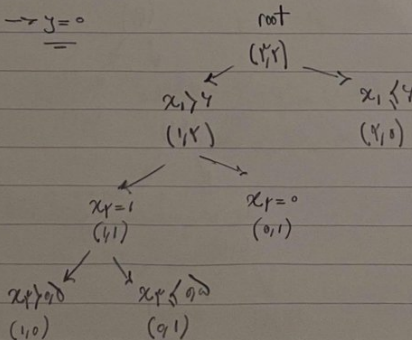


$x_4: H(Y|x_4) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91$

$x_5: \begin{array}{c|c} 0 & 1 \end{array} \rightarrow H(Y|x_5) = -\frac{1}{2} \log \frac{1}{2} - \frac{1}{2} \log \frac{1}{2} = 0.91$

$\rightarrow$  split on  $x_4$ , then split on  $x_5$  : ML Decision Tree :

for  $x_1=1, x_2=0, x_3=0, x_4=0 \rightarrow y=0$




Computer Architecture  $\rightarrow H(Y) = 0.921$ 

$$\begin{aligned}
 \square x_1: & \begin{array}{c} 2 \quad 1 \quad 0 \quad 1 \\ \textcircled{1} \quad \textcircled{0} \quad \textcircled{1} \end{array} \quad \left. \begin{array}{l} H(Y|1) = -1/8 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) = 0.1 \\ H(Y|0) = -1/8 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) = 0.2091 \\ H(Y|1) = -1/8 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/8 \log_2 0 = 0.1 \end{array} \right\}
 \end{aligned}$$

$$\square x_2: H(Y|x_2) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 0 = 0.921$$

$$\begin{aligned}
 \square x_2: & \begin{array}{c} 0.1 \quad 0.1 \quad 0.1 \quad 0.1 \\ \textcircled{1} \quad \textcircled{0} \quad \textcircled{1} \end{array} \quad \left. \begin{array}{l} H(Y|1) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) = 0.921 \\ H(Y|0) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 0 = 0.2091 \\ H(Y|1) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 0 = 0.1 \end{array} \right\}
 \end{aligned}$$

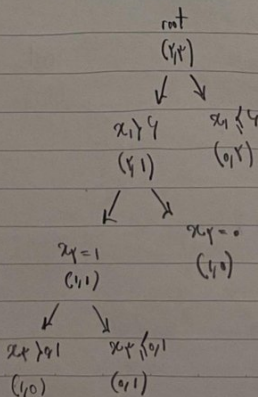
 $\rightarrow$  split on  $x_1, y$  $\checkmark$  continue on  $x_1, y$ 

$$\square x_2: H(Y|x_2) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 0 = 1/4$$


$$\square x_2: \begin{array}{c} 0.1 \quad 0.1 \end{array} \rightarrow H(Y|x_2) = -1/4 \log_2 (1/4 \log_2 1/4 + 1/4 \log_2 1/4) - 1/4 \log_2 0 = 1/4$$

 $\rightarrow$  split on  $x_2$ , then on  $x_2$ : CA Decision Tree:

$$\text{for } x_1=1, x_2=1, x_2=0, y=1$$



Naïve Bayes:



(1) (2)

$$P(Y, x_1=1, x_2=0, x_3=0) \rightarrow P(Y=1, \text{features}) = p q^r$$

$$P(Y=0, \text{features}) = 0.8(1-p)(1-q)^r$$

$$\rightarrow P(Y=1 | \text{features}) = \frac{P(Y=1, \text{features})}{P(\text{features})} = \frac{p q^r}{p q^r + (1-p)(1-q)^r}$$

$$\text{if } P(Y=1 | \text{features}) > 0.5 \rightarrow \underline{Y=1}$$

$$\underline{p q^r > (1-p)(1-q)^r} \quad \text{Cond (1)}$$

! process the  $x_2, x_3$  & the feature,  $p$  is the prob. of  $x_1$  class 1 &  $q$  is the prob. of  $x_1$  class 0.


$$\begin{aligned} P(Y=1, \text{features}) &= p q^r \\ P(Y=0, \text{features}) &= 0.8(1-p)(1-q)^r \end{aligned} \quad \left\{ \begin{aligned} P(Y=1 | \text{features}) &= \frac{P(Y=1, \text{features})}{P(\text{features})} = \frac{p q^r}{p q^r + (1-p)(1-q)^r} \end{aligned} \right.$$

$$\text{if } P(Y=1 | \text{features}) > 0.5 \rightarrow \underline{Y=1}$$

$$\underline{p q^r > (1-p)(1-q)^r} \quad \text{Cond (2)}$$

Error in Naïve Bayes :  $C_1 \cap C_2$  or  $C_2 \cap C_1 = C_1 \oplus C_2$

(3)



$$\text{Cond (1)} \rightarrow p q = (1-p)(1-q)$$

$$p = 1-q$$

$$\text{Cond (2)} \rightarrow p q^2 = (1-p)(1-q)^2$$

10  
class class

! process the Naïve Bayes,  $x_2$  &  $x_3$  &  $x_1$




input = step (Z) ...  
 output = step (Z) ...

حال بہ برکت کی ہے

این به همین ترتیب برای  $n$  ادامه دهیم و برای  $check$  output  $k$   $check$  را به  $check + 1$  می‌کنیم.

میری بہ منزلت (۵۰) وضع ہوا بہ طور ۸ — ۱۶۱ کھ، ۱۲۱ کھ —



این شبهه عین زانی فاعله و نه متعلقه (یا) چون این مفعول متعلقه به

[illegible]

$$x \sin \theta + y \cos \theta \leq f$$

نقطه‌ای باشد که در ناحیه باشد :

$$x \sin \theta + y \cos \theta \geq -f$$

$$x \sin 130 + y \cos 130 \leq f$$

$$x \sin 130 + y \cos 130 \geq -f$$

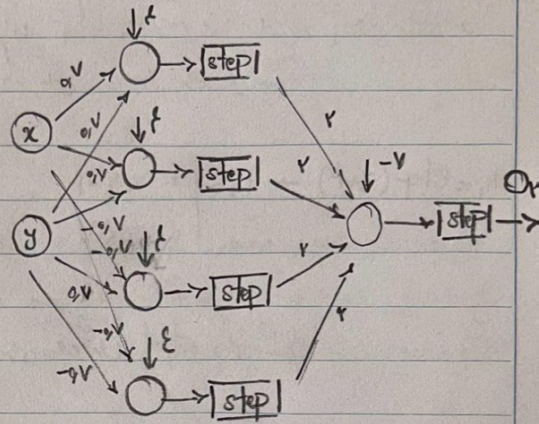

$$\downarrow \sqrt{f^2} = 0.1V$$

$$0.1Vx + 0.1Vy \leq f$$


$$-0.1Vx - 0.1Vy \leq f$$

$$-0.1Vx + 0.1Vy \leq f$$

$$0.1Vx - 0.1Vy \leq f$$



در حالتی که این شبکه را می‌خواهیم به کار ببریم باید به این نکته توجه کنیم که این شبکه را باید به گونه‌ای تنظیم کنیم که بتواند به درستی عمل کند.



این شبکه را می‌توان به گونه‌ای تنظیم کرد که بتواند به درستی عمل کند.

این شبکه را می‌توان به گونه‌ای تنظیم کرد که بتواند به درستی عمل کند.



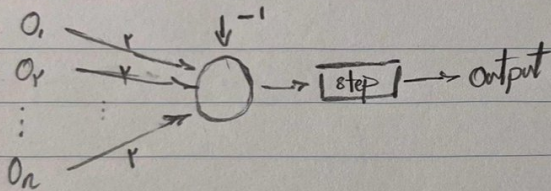
for  $i = 1$  to  $n$ :

$$|x \sin \theta_i + y \cos \theta_i| \leq \epsilon$$

$$|x \sin (\theta_i + \pi/r) + y \cos (\theta_i + \pi/r)| = |-x \cos \theta_i + y \sin \theta_i| \leq \epsilon$$

$$\theta_i = \frac{(i-1)\pi}{rn} \rightarrow \frac{\pi}{r} \cdot i \text{ is constant}$$

for  $i = 1$  to  $n$  do  
 for  $j = 1$  to  $r$  do  
 if  $|x \sin (\theta_i + \pi/r) + y \cos (\theta_i + \pi/r)| > \epsilon$  then  
 return false  
 end for  
end for  
return true



$$\text{Dataset: } \{y_i, x_{i1}, \dots, x_{in}\}_{i=1}^n \rightarrow y_i = \sum_{j=1}^n \beta_j x_{ij} + \beta_0 + e_i$$

(1) (2)

$$\text{let } x_i = [1, x_{i1}, \dots, x_{in}]^T \quad y_i = \beta^T x_i + e_i$$

$$\beta = [\beta_0, \beta_1, \dots, \beta_n]^T \quad \text{for } i = 1 \dots n$$

$$\text{let } X \text{ be matrix} = [x_1, \dots, x_n]^T = \begin{bmatrix} 1 & x_{11} & \dots & x_{1n} \\ 1 & x_{21} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \dots & x_{nn} \end{bmatrix}$$

$$y = [y_1, \dots, y_n]^T$$

$$e = [e_1, \dots, e_n]^T$$

⇒ equation in matrix form:  $y = X\beta + e$  with loss function  $\|e\|_Y^2$

$$\text{minimize } \arg \min_{\beta} \|e\|_Y^2 = \arg \min_{\beta} \|y - X\beta\|_Y^2 \quad (3)$$

$$\|y - X\beta\|_Y^2 = (y - X\beta)^T (y - X\beta) = (y^T - \beta^T X^T) (y - X\beta) = y^T y - \beta^T X^T y - y^T X \beta + \beta^T X^T X \beta$$

$$\frac{d}{d\beta} \|y - X\beta\|_Y^2 = y^T X^T \beta - y^T X^T y = 0 \rightarrow \text{for } \arg \min \beta$$

$$\rightarrow X^T X \hat{\beta} = X^T y$$

lemma:  $X^T X$  is invertible

$$\rightarrow \hat{\beta} = (X^T X)^{-1} X^T y$$

$$\text{loss function} = \|e\|_Y^2 + \lambda \|\beta\|_Y^2 \quad (4)$$

$$\arg \min_{\beta} \|e\|_Y^2 + \lambda \|\beta\|_Y^2 = \arg \min_{\beta} \|y - X\beta\|_Y^2 + \lambda \|\beta\|_Y^2$$

$$\|y - X\beta\|_Y^2 + \lambda \|\beta\|_Y^2 = y^T y - \beta^T X^T y - y^T X \beta + \beta^T X^T X \beta + \lambda \beta^T \beta$$

$$\frac{d}{d\beta} \text{loss function} = y^T X^T \beta - y^T X^T y + \lambda \beta = 0 \rightarrow \text{for } \arg \min \beta$$

$$\rightarrow (X^T X + \lambda I) \hat{\beta} = X^T y$$

$$\rightarrow \hat{\beta} = (X^T X + \lambda I)^{-1} X^T y$$

let  $w^*$  be  $\operatorname{argmin}_w \{ \|w\| : \forall i \in [m], y_i \langle w, x_i \rangle \geq 1 \}$  (i) (as class

$$\langle w^*, w^{(t+1)} \rangle - \langle w^*, w^{(t)} \rangle = \langle w^*, w^{(t+1)} - w^{(t)} \rangle = \langle w^*, y_i x_i \rangle = y_i \langle w^*, x_i \rangle \geq 1 \quad (\text{on the def. of } w^*)$$

$$w^{(1)} = (0, \dots, 0) \rightarrow \langle w^*, w^{(1)} \rangle = 0 \quad \text{if update occurs}$$

$$\rightarrow \langle w^*, w^{(T+1)} \rangle = \sum_{t=1}^T (\langle w^*, w^{(t+1)} \rangle - \langle w^*, w^{(t)} \rangle) \geq T \quad (1)$$

$$\|w^{(t+1)}\|^2 = \|w^{(t)} + y_i x_i\|^2 = \|w^{(t)}\|^2 + y_i^2 \|x_i\|^2 + 2 y_i \langle w^{(t)}, x_i \rangle$$

• update  $\leftarrow$   $\leftarrow$

$$\rightarrow \|w^{(t+1)}\|^2 \leq \|w^{(t)}\|^2 + R^2 \rightarrow \|w^{(T+1)}\|^2 \leq TR^2$$

$$\|w^{(T+1)}\| \leq \sqrt{TR} \quad (2)$$

$$(3) \|w^*\| = B$$

$$\xrightarrow{y_i, x_i} \frac{\langle w^*, w^{(T+1)} \rangle}{\|w^*\| \|w^{(T+1)}\|} \leq \frac{T}{B \times \sqrt{TR}} = \frac{\sqrt{T}}{RB} \rightarrow 1 \geq \frac{\sqrt{T}}{RB}$$

• it is  $\frac{1}{B \times \sqrt{TR}}$   $\frac{1}{B \times \sqrt{TR}}$

$$\rightarrow (RB)^2 \geq T$$

✓  $\leftarrow$   $\leftarrow$



$$\{(e_i, y_i = 1)\}_{i=1}^m$$

ب) مقدار  $d=m$  و  $d$  نسبت به  $n$  را اولی می باشد:

همچنین بدون کاهش دقت، مقدار  $d$  را  $d=1$  می گیریم  $Sign(0) = -1$

از این روش،  $w$  را به دست می آوریم و  $w$  را به یک بردار وزن ها در مرحله اول از الگوریتم در مقدار  $d=1$  قرار می دهیم:

$$w_i = \sum_{j=1}^n x_{ij} e_j$$

برای  $d$  هر مرحله، مقدار  $\{w_i, x_i, y_i\}$  مقدار  $w_i$  و به بردار  $w$ ، مقدار  $y_i \cdot x_i = e_i$  اولی می گذاریم. در نتیجه بردار  $w$  را ابتدا طبق  $m$  طبقه می گزینیم و به ترتیب در  $m$  مرحله به روز می کنیم.

در نهایت طبق  $w$  پس از  $m$  مرحله به بردار  $w$  می گذاریم. این بردار را  $w_m$  می نامیم.

$$\|w_m\|^2 = m, \forall i, y_i \{w_m, x_i\} = 1 \rightarrow \text{حالت بهینه}$$

در طبقه بندی پس از  $d$  مقدار مرحله  $d$ ،  $T$  نشان می دهد از  $(RB)^T$  که  $T$  به این شکل و  $d$  را داریم:

$$\left\{ \begin{array}{l} \sqrt{m} \text{ } \beta \\ 1 \text{ } R \end{array} \right\} (RB)^T \left\{ \begin{array}{l} m \\ T \end{array} \right\} \left\{ \begin{array}{l} (RB)^T \\ \text{برای } d=1 \\ \text{است} \end{array} \right\}$$

$$(RB)^T \leftarrow (T)$$

$T = m$

برای این مدل  $T = m$